

온디바이스 sLLM용 K26-Memory FPGA 후보 구조: 확장 기술보고서

Extended Technical Report on Dependency-Aware Mapping, Closed Logical RTL, and Placement
Sensitivity

최윤혁 (CHOI YUNHYUK) · 한국디지털미디어고등학교 · ORCID 0009-0006-3537-0249

2026-08-01

초록

온디바이스 소형 언어 모델은 서버급 가속기를 사용하기 어려워 메모리 용량과 가중치 공급 대역폭을 제한된 전력·비용 안에서 함께 해결해야 한다. 본 연구는 Kria K26이 연산·제어를 맡고 외부 Memory FPGA가 다채널 가중치 공급을 맡는 확장형 후보 구조를 설계했다. 정적 작업 배정으로 일부 연산 클러스터가 유휴 상태에 빠질 때는 데이터 이동 비용을 고려한 작업 훔치기(Work Stealing)를 선택적으로 사용한다. 실제 Gemma 3 1B 그래프의 7,837개 노드에서 토큰당 183개 투영 연산을 추출하고, 이를 의존성이 있는 802개 출력 타일로 변환해 네 가지 초기 배치와 세 가지 대기열 정책을 비교했다. 합성 불균형 부하에서 지역성 인식 정책은 정적 배치보다 TileJob p95를 19.13% 줄이고, 단순 작업 훔치기보다 비지역 가중치 이동량을 35.49% 줄였다. 그러나 Gemma 형상에서는 초기 배치에 따라 p95 변화가 +0.28%에서 -19.79%까지 달라졌으며, K26 로컬 메모리 기준선도 외부 6.4 GB/s 후보보다 짧았다. 따라서 외부 8GB와 작업 재분배는 Gemma 1B의 필수 구성요소가 아니라 더 큰 모델·긴 문맥·로컬 경합이 확인될 때 채택할 확장 수단이다. 결과는 제한된 RTL 시뮬레이션과 분석 모델에 근거하며 보드 실측값이 아니다.

핵심어: 온디바이스 sLLM, Kria K26, Memory FPGA, 다채널 메모리, 작업 훔치기, SpinalHDL

Abstract

On-device small language models must address memory capacity and weight-delivery bandwidth within tighter power and cost limits than server accelerators. This work evaluates an extensible candidate architecture in which a Kria K26 handles control and computation while an external Memory FPGA supplies weights through multiple memory channels. Locality-aware work stealing is enabled only when static placement leaves compute clusters idle and its expected benefit exceeds data-movement cost. From the 7,837-node Gemma 3 1B graph, 183 projections per token are mapped to 802 dependency-aware output tiles and evaluated under four initial placements and three queue policies. On a synthetic skew workload, the locality-aware policy reduces TileJob p95 by 19.13% against static placement and non-local weight movement by 35.49% against oldest-job stealing. On Gemma-shaped tiles, however, the p95 effect ranges from +0.28% to -19.79% depending on initial placement, and the modeled K26-local baseline remains shorter than the external 6.4-GB/s candidate. External 8GB memory and work stealing are therefore conditional expansion mechanisms rather than requirements for Gemma 1B. The results are based on bounded RTL simulation and analytical models, not board measurements.

Keywords: on-device sLLM, Kria K26, Memory FPGA, multi-channel memory, work stealing, SpinalHDL

I. 서론

온디바이스 환경에서는 서버급 GPU의 전력과 가격을 그대로 사용할 수 없다. 모델이 메모리에 들어가는지만 보는 것도 충분하지 않다. 연산부가 가중치를 기다리는 시간, 운영체제·활성값·KV cache가 쓰는 로컬 메모리와 가중치 공급의 경합, 여러 연산 클러스터 사이의 부하 균형이 함께 성능을 결정한다.

본 연구는 처음에 외부 메모리가 Gemma 3 1B의 용량 때문에 필요하다고 가정했다. 그러나 INT8 가중치와 32K 문맥의 용량을 계산한 결과 2.43 GiB로, 명목상 K26 로컬 4GB에 들어갔다. 이에 연구 질문을 “외부 메모리가 필요한가”에서 “가중치 공급을 로컬 실행 메모리와 분리하는 구조는 어떤 조건에서 이득인가”로 바꾸었다.

제안 후보는 K26의 연산·제어와 Memory FPGA의 다채널 가중치 공급을 분리한다. K26에는 네 연산 클러스터와 독립 대기열을 두고, 외부 쪽에는 네 DDR3L x16 채널과 네 논리 링크를 둔다. 정적 배정이 데이터 지역성을 지키더라도 작업이 한쪽에 몰리면 일부 클러스터가 놀 수 있다. 이때만 유휴 클러스터가 다른 대기열의 작업을 가져오며, 이미 배치된 가중치와 활성값을 옮기는 비용을 함께 계산한다.

본 연구의 기여는 다음과 같다. 첫째, 로컬 실행 메모리와 외부 가중치 공급 메모리의 역할을 분리한 온디바이스 확장 후보를 제시하고 K26 로컬 기준선과 비교했다. 둘째, 원격 복사 시간을 실제 링크 서비스에 부과해 초기 배치와 작업 재분배의 효과를 분리했다. 셋째, 실제 Gemma 그래프의 형상에서 TileJob을 만들고, 제한된 실제 가중치 타일이 DMA 명령·메모리 응답 경계·논리 링크·MatVec까지 통과하는 재현 가능한 흐름을 구현했다.

 그림 1. K26의 연산·제어와 Memory FPGA의 가중치 공급을 분리한 후보 구조. 굵은 실선은 연결된 논리 RTL 경로이며, 점선의 GTH·MIG는 후속 물리 구현 범위다.

그림 1. K26의 연산·제어와 Memory FPGA의 가중치 공급을 분리한 후보 구조. 굵은 실선은 연결된 논리 RTL 경로이며, 점선의 GTH·MIG는 후속 물리 구현 범위다.

II. 관련 연구와 연구 공백

PagedAttention[1]은 KV cache의 페이지 관리 문제를, FlashAttention[2]은 attention 연산의 데이터 이동을 줄이는 방법을 다룬다. GPTQ[3], SmoothQuant[4], AWQ[5]는 모델 크기와 양자화 정확도의 균형을 연구한다. 이 연구들은 메모리 이동이 중요하다는 근거를 제공하지만, 여러 로컬 대기열과 외부 가중치 공급 링크를 함께 가진 소형 FPGA 구조의 초기 배치 문제를 직접 다루지 않는다.

FTRANS[6], DFX[7], FlightLLM[8]은 Transformer의 FPGA 매핑과 다중 FPGA 실행 구조를 제시했다. 이들은 완성된 매핑 흐름이나 처리량을 중심으로 평가한다. 본 연구는 최고 처리량 경쟁보다 설계 조건 규명에 초점을 둔다. K26 로컬 메모리와 외부 다채널 메모리 후보를 같은 작업 형상에서 비교하고, 작업 재분배가 가중치 복사 비용을 감수할 조건을 찾는다.

고전적 작업 흠치기[15]는 의존 작업의 부하 균형을 설명하고, LAWS[16]는 NUMA 환경에서 원격 메모리 비용을 고려한다. 본 연구의 정책은 이들보다 이론적으로 새롭다고 주장하지 않는다. 연구 공백은 실제 sLLM 투영 형상, FPGA 메모리 분리 구조, 초기 배치, 비지역 전송 비용을 하나의 공개 설계 흐름에서 비교한 자료가 부족하다는 점이다.

III. 온디바이스 가속기의 설계 목표

대상은 3B 이하 sLLM을 향한 확장형 후보이며, 이번 평가는 Gemma 3 1B를 사용한다. K26 로컬 4GB는 운영체제와 실행 환경, 활성값, KV cache, 자주 쓰는 데이터를 담당한다. 외부 메모리는 상주 가중치, 다음 층 사전 적재, 용량 확장을 담당하도록 역할을 나눈다.

표 1. 설계 목표와 이번 평가의 범위

항목	목표	이번 평가
연산	K26의 다중 연산 클러스터	부호 있는 INT8 MatVec 클러스터 4개
로컬 메모리	실행 환경·활성값·KV cache	4.8~14.4 GB/s 유효 대역폭 민감도
외부 메모리	8GB 이상, 채널·랭크 확장	4×DDR3L x16, 3.2~12.8 GB/s 분석
링크	Memory FPGA→K26 가중치 전송	논리 링크 4개, 64~256비트 민감도
작업 배치	지역성과 부하 균형	정적·라운드로빈·크기 균형·채널 친화
물리 검증	GTH·MIG·전원·보드 계측	논리 RTL과 라우팅 쿠폰까지만 수행

외부 8GB는 Gemma 1B가 4GB에 들어가지 않아서 선택한 것이 아니다. 더 큰 모델과 긴 문맥으로 확장하거나, 로컬 실행 메모리의 경합을 줄이고, 여러 클러스터에 독립적인 가중치 공급 경로를 제공하기 위한 후보이다. 따라서 외부 구조는 K26 로컬 기준선보다 나은 조건을 보여야 채택할 수 있다.

IV. K26-Memory FPGA 시스템 구조

K26 측의 입력 명령은 작업 정보와 활성값만 포함한다. 명령은 DMA 요청 FIFO를 거쳐 외부 메모리 채널에 가중치를 요청한다. Memory FPGA 경계에서 돌아온 가중치 타일은 작업의 선호 링크에 따라 네 논리 FIFO 중 하나로 들어간다. K26은 작업 ID로 보관 중인 활성값과 응답 가중치를 결합하고, 대기열 정책이 선택한 클러스터에서 MatVec을 수행한다.

논리 가상 시제품은 작업 수락→DMA 요청→채널 스케줄러→DDR 응답 경계→논리 링크 FIFO→입력 결합→MatVec 결과를 하나의 역압 흐름으로 연결한다. 가중치 응답이 없으면 연산 명령을 만들 수 없고, 동일 작업 ID의 응답은 한 번만 수락한다. 실제 Gemma 파일에서 제한적으로 추출한 세 개의 16×4 INT8 가중치 타일이 이 경로를 통과해 소프트웨어 INT32 결과와 모두 일치했다.

이 연결은 물리 링크가 완성되었다는 뜻이 아니다. 링크 FIFO는 넓은 논리 응답을 전달하며 GTH 직렬화, 레인 결합, CDC, 패킷 분할, CRC 재전송, 크레딧 반환은 포함하지 않는다. 메모리 응답도 MIG 경계에서 주입하므로 DDR3L PHY와 보정 과정을 검증하지 않는다. 그림 1은 이 차이를 실선과 점선으로 구분한다.

표 2. 결과를 해석할 때의 증거 구분

구분	포함 내용	허용되는 해석
직접 확인	ONNX 노드·형상, 실제 타일 3개, KiCad 원본	해당 파일과 제한 경로의 사실
RTL 시뮬레이션	단힌 논리 경로, 정확히 한 번 처리, MatVec 결과	논리 기능과 역압
분석 모델	대기열, 링크·메모리 서비스, 배치 민감도	명시한 가정 안의 상대 비교
미검증	GTH·MIG 타이밍, 보드 전력, SI/PI, 전체 가격	후속 구현·계측 과제

V. Gemma 3 1B 작업의 하드웨어 매핑

로컬에 보관된 Gemma 3 1B ONNX 그래프는 7,837개 노드와 토큰당 183개 밀집 투영 연산을 가진다. Attention의 q, k, v, o가 104개, MLP의 gate, up, down이 78개, lm_head가 1개다. 원본 float32 투영 가중치는 약 4.0GB이며, 평가에서는 명시적인 INT8 변환을 가정해 약 1.0GB로 모델링했다. 모델 가중치 자체는 공개 저장소에 배포하지 않는다.

각 투영은 전체 K차원을 유지하고 $N \leq 1024$ 인 출력 타일로 나누어 토큰당 802개 TileJob을 만든다. q/k/v가 끝난 뒤 o, o가 끝난 뒤 gate/up, 이 둘이 끝난 뒤 down을 내보낸다. 다음 계층은 이전 down 뒤에 시작하고, 다음 토큰은 lm_head가 끝난 뒤에만 시작한다. 32토큰 조건은 이 의존성 인식 토큰을 중첩 없이 직렬 반복한 25,664개 TileJob이다.

그림 2. 실제 Gemma 그래프의 투영 연산을 의존성이 있는 출력 TileJob으로 변환하는 과정. 배치 규칙은 그래프 사실이 아니라 별도 모델 변수다.

그림 2. 실제 Gemma 그래프의 투영 연산을 의존성이 있는 출력 TileJob으로 변환하는 과정. 배치 규칙은 그래프 사실이 아니라 별도 모델 변수다.

초기 배치는 네 가지다. 기존 산술 규칙은 토큰당 타일 수가 C0/C1/C2/C3에 464/208/78/52로 치우친다. 라운드로빈은 타일 수를 균등하게 나눈다. 크기 균형 배치는 누적 MAC 수가 가장 작은 클러스터에 다음 타일을 둔다. 채널 친화 배치는 가중치가 있는 채널과 같은 번호의 클러스터를 우선한다. 네 배치 모두 실제 컴파일러 결과가 아니라 설계 변수이며, 이 비교로 “초기 배치를 잘한 효과”와 “작업을 나중에 옮긴 효과”를 분리한다.

VI. 다중 대기열과 지역성 인식 작업 재분배

S1은 각 클러스터가 자기 대기열만 선착순으로 처리하는 정적 기준선이다. S2는 유휴 클러스터가 다른 대기열에서 가장 오래 기다린 작업을 가져온다. S3는 기다린 시간에서 가중치 크기, 활성값 이동, 부분합 반환, 링크 불일치 비용을 뺀 점수가 양수일 때만 작업을 가져온다.

그림 3. 정적 다중 대기열과 지역성 인식 작업 재분배. 옮긴 작업은 기본 위치에 가중치를 먼저 적재한 뒤 유휴 클러스터로 복사하며, 추가 바이트와 사이클을 링크 서비스에 부과한다.

그림 3. 정적 다중 대기열과 지역성 인식 작업 재분배. 옮긴 작업은 기본 위치에 가중치를 먼저 적재한 뒤 유휴 클러스터로 복사하며, 추가 바이트와 사이클을 링크 서비스에 부과한다.

이번 모델은 작업 옮치기의 비용을 사후 통계로만 세지 않는다. 정적 배치가 선호 링크로 가중치를 먼저 공급했다고 가정하고, 옮긴 작업은 가중치·활성값·부분합을 실행 클러스터 쪽 링크로 다시 복사한다. 기본 전송과 추가 전송의 바이트와 사이클을 분리해 저장한다. 따라서 S3가 더 작은 작업을 고르면 S2보다 비지역 전송량을 줄일 수 있지만, 복사 자체가 정적 S1보다 완료시간을 늘릴 수도 있다.

S3는 상시 정책이 아니다. 균형 배치에서는 옮길 이유가 없고, 메모리 채널 자체가 병목이면 빈 클러스터를 채워도 완료시간이 줄지 않는다. 정책을 켜는 조건은 예상 대기 감소가 추가 데이터 이동 시간보다 큰 경우이다.

VII. 구현과 평가 방법

RTL은 SpinalHDL로 작성하고 Verilator로 시뮬레이션했다. 직접 확인한 경로는 세 실제 가중치 타일의 작업 수락, DMA 명령, DDR 응답 경계, 링크 FIFO, MatVec 결과이다. 별도의 세 작업 합성 시험 입력은 S3 스케줄러가 작업 ID를 보존하며 세 작업을 흠치고 정확히 한 번 완료하는지 확인한다.

 그림 4. 실제 Gemma 대표 타일 세 개가 페루프 논리 RTL 경로를 통과한 사이클 추적. 세 결과는 소프트웨어 INT32 기준과 일치한다.

그림 4. 실제 Gemma 대표 타일 세 개가 페루프 논리 RTL 경로를 통과한 사이클 추적. 세 결과는 소프트웨어 INT32 기준과 일치한다.

분석 모델은 클러스터 4개, 메모리 채널 4개, 논리 링크 묶음 4개, 묶음당 128비트를 기본값으로 사용한다. 합성 부하는 균형, 편향, 채널 집중, 순간 집중, 혼합의 1,000개 작업을 5개 시드에서 생성한다. 같은 작업 부하와 시드의 모든 정책은 동일한 작업 목록 해시를 사용한다. 정책별 중앙값을 나누지 않고 시드별 변화율을 먼저 계산한 뒤 그 중앙값과 범위를 보고한다.

Gemma 평가는 모델에서 추출한 K/N 형상과 보수적 단계 의존성을 사용한다. p95와 p99는 개별 TileJob이 의존성에서 해제된 시점부터 완료될 때까지의 분포이다. 사용자 요청 단위의 꼬리 지연이 아니다. 32토큰 시간은 동일한 토큰 모델의 직렬 반복이며 기능적 텍스트 생성도 아니다.

K26 로컬 기준선은 외부 링크를 제거하고 공유 로컬 메모리의 유효 대역폭을 4.8, 9.6, 14.4 GB/s로 바꾼다. 외부 후보는 네 채널의 합을 3.2, 6.4, 12.8 GB/s로 바꾸고 링크 폭을 64, 128, 256비트로 비교한다. 이 값들은 측정값이 아니라 채택 임계값을 찾는 민감도이다.

VIII. 결과와 시스템 설계 결정

A. 합성 불균형 부하

합성 편향 부하에서 S3는 S1보다 TileJob p95를 19.13%, p99를 18.71% 줄였다. 전체 완료시간도 17.25% 짧았다. S2와 비교하면 비지역 가중치 이동량을 35.49% 줄였고 완료시간 중앙값 차이는 +0.01%로 거의 같았다. 혼합 부하에서도 S1 대비 p95가 17.70% 줄었다. 균형 부하에서는 변화가 없고 채널 집중 부하에서는 p95 변화가 0%였다.

 그림 5. 동일한 다섯 시드를 찍지어 비교한 합성 부하 결과. 작업 불균형이 큰 편향과 혼합 부하에서만 꼬리 지연 감소가 나타난다.

그림 5. 동일한 다섯 시드를 찍지어 비교한 합성 부하 결과. 작업 불균형이 큰 편향과 혼합 부하에서만 꼬리 지연 감소가 나타난다.

표 3. 합성 부하의 S3 효과, 동일 시드 쌍비교 중앙값

부하	S1 대비 완료시간	S1 대비 TileJob p95	S1 대비 p99	S2 대비 비지역 가중치
균형	0.00%	0.00%	0.00%	해당 없음
채널 집중	-0.06%	0.00%	0.00%	0.00%
순간 집중	-1.79%	-0.08%	-1.16%	-15.25%
혼합	-15.91%	-17.70%	-16.92%	-22.60%
편향	-17.25%	-19.13%	-18.71%	-35.49%

이 결과는 작업 불균형이 데이터 이동 비용보다 큰 조건에서만 작업 재분배가 유효하다는 가설을 지지한다. 합성 편향 부하의 수치를 실제 Gemma 실행 결과로 해석해서는 안 된다.

B. Gemma 형상과 초기 배치

Gemma 형상에서는 초기 배치가 결과를 지배했다. 기존 산술 배치에서 S3는 S1보다 완료시간이 4.80% 길고 p95도 0.28% 길었다. 원격 복사 비용을 부과하면 빈 클러스터를 채운 이득보다 이동 비용이 더 컸다. 라운드로빈과 크기 균형 배치에서는 p95가 변하지 않았고 완료시간만 1% 미만 줄었다. 채널 친화 배치에는 큰 작업 풀림이 남아 S3가 완료시간을 7.56%, p95를 19.79% 줄였다.

 그림 6. 같은 Gemma 형상에서 초기 배치에 따라 S3의 효과가 바뀐다. 배치가 이미 균형이면 꼬리 지연 이득이 없다.

그림 6. 같은 Gemma 형상에서 초기 배치에 따라 S3의 효과가 바뀐다. 배치가 이미 균형이면 꼬리 지연 이득이 없다.

표 4. Gemma 의존성 인식 TileJob의 S3 효과

초기 배치	타일 수 C0/C1/C2/C3	완료시간 변화	TileJob p95 변화	추가 링크 전송
기존 산술 규칙	464/208/78/52	+4.80%	+0.28%	395.2 MB/토콘
라운드로빈	201/201/200/200	-0.59%	0.00%	43.3 MB/토콘
크기 균형	198/202/200/202	-0.76%	0.00%	110.8 MB/토콘
채널 친화	394/136/136/136	-7.56%	-19.79%	416.4 MB/토콘

결론은 “Gemma에서 작업 훔치기가 빠르다”가 아니다. 초기 배치가 충분히 균형이면 작업을 옮길 필요가 없다. 채널 지역성을 우선해 큰 불균형이 남은 경우에만 선택적 재분배가 의미가 있다.

C. K26 로컬과 외부 메모리 후보

크기 균형 S1에서 K26 로컬 4.8/9.6/14.4 GB/s의 완료시간은 각각 45.0M/24.6M/17.8M 사이클이었다. 외부 4채널 3.2/6.4/12.8 GB/s 후보는 238.3M/120.6M/62.4M 사이클이었다. 외부 6.4 GB/s 조건은 링크 폭을 64비트에서 256비트로 넓혀도 거의 바뀌지 않아 메모리 공급이 병목이었다.

이 민감도에서는 외부 후보가 Gemma 1B의 성능 기준선을 이기지 못한다. 또한 INT8 문맥 길이 32K의 용량 2.43 GiB가 로컬 4GB 안에 들어가므로 용량 채택 근거도 없다. 외부 Memory FPGA는 3B·더 긴 문맥·실제 로컬 경합을 평가할 다음 구조 후보이며, Gemma 1B의 기본 구성은 K26 로컬이다.

비용 자료는 DDR3L 부품 가격 조사 시점 자료만 포함하고 K26, FPGA, PCB, 전원, 냉각, 조립을 제외한다. 에너지도 MAC·링크·DRAM 동적 항의 민감도일 뿐이다. 따라서 저비용·저전력은 설계 목표이지 이번 연구가 실물로 달성한 결과가 아니다.

IX. PCB 인터페이스 라우팅 쿠폰

KiCad 자료는 전체 Memory FPGA 보드가 아니라 인터페이스 배선의 공간을 검토한 쿠폰이다. J1은 XC7K160T의 DDR/GTH bank 경계를, J2는 K26 GTH 경계를 대신한 범용 Samtec 커넥터다. U1은 네 메모리 채널 중 DDR3L x16 한 슬라이스만 나타낸다. 실제 K26 SOM 커넥터 핀과 FPGA BGA ball, 네 MIG 채널, 전원 트리, 부트 회로는 포함하지 않는다.

 그림 7. 실제 KiCad 원본에서 렌더링한 인터페이스 라우팅 쿠폰. 두 범용 경계 커넥터, 대표 DDR3L x16 슬라이스, GTH·refclk 배선을 표시한다. NOT FOR FABRICATION.

그림 7. 실제 KiCad 원본에서 렌더링한 인터페이스 라우팅 쿠폰. 두 범용 경계 커넥터, 대표 DDR3L x16 슬라이스, GTH·refclk 배선을 표시한다. NOT FOR FABRICATION.

쿠폰은 29개 부품 배치와 20개 배선된 GTH/기준 클록 신호망을 포함하며 선언된 제한 범위의 ERC/DRC는 0건이다. 그러나 전체 116개 신호망 중 55개가 미배선이고, 고속 신호 귀환 경로와 접지 비아 배치, 시험점, 정확한 부품 출처가 완성되지 않았다. 이 자료가 지지하는 주장은 “대표 링크와 DDR 배선의 위치 관계를 KiCad 객체로 구체화했다”는 것뿐이다. 제작 가능성, SI/PI, 온도, 실제 대역폭은 검증하지 않았다.

X. 논의와 한계

첫째, Gemma 작업의 K/N 형상과 투영 순서는 실제 모델에서 얻었지만 초기 클러스터·채널·링크 배치는 모델 변수다. 실제 컴파일러나 실행 환경의 배치가 생기면 네 민감도 중 어느 조건에 가까운지 다시 확인해야 한다. 둘째, 단계 장벽은 잘못된 병렬 실행을 막는 보수적 모델이며 실제 연산자의 세부 중첩 실행을 재현하지 않는다. 셋째, p95와 p99는 TileJob 분포이지 사용자 요청 분포가 아니다.

넷째, 닫힌 RTL 경로는 논리 가상 시제품이다. GTH·MIG·CDC·패킷 프로토콜을 구현하고 Vivado 타이밍을 달아야 물리 대역폭을 말할 수 있다. 다섯째, K26 로컬 대역폭과 전력은 민감도 입력이다. 실제 보드에서 같은 작업을 실행해 로컬 경합과 전체 전력을 측정해야 외부 메모리 채택을 결정할 수 있다.

후속 검증 순서는 명확하다. 먼저 실제 K26 로컬 대역폭·경합·전력을 측정한다. 다음으로 논리 응답을 패킷 단위로 나누고 GTH·CDC·크레딧 경로를 구현한다. 그 뒤 MIG 타이밍과 한 채널의 정확한 핀·전원·배선을 닫고 SI/PI 검증을 진행한다. 이 관문을 통과하기 전에는 전체 보드를 제작 대상으로 취급하지 않는다.

XI. 결론

본 연구는 K26의 연산·제어와 외부 Memory FPGA의 가중치 공급을 분리한 온디바이스 sLLM 확장 후보를 설계하고, 실제 Gemma 형상에서 초기 배치와 작업 재분배의 조건을 평가했다. 합성 불균형 부하에서는 지역성 인식 작업 재분배가 TileJob p95와 비지역 가중치 이동을 함께 줄였다. 그러나 의존성과 이동 비용을 반영한 Gemma 형상에서는 배치에 따라 이득이 사라지거나 완료시간이 악화되었다.

따라서 작업 흠치기는 이 구조의 주인공이 아니라, 초기 배치 후 남은 불균형이 이동 비용보다 클 때만 켜는 수단이다. Gemma 1B는 K26 로컬을 우선하고, 외부 8GB는 더 큰 모델·긴 문맥·실제 로컬 경합이 확인될 때 채택한다. 실제 모델 그래프, 출력 TileJob, 페루프 논리 RTL, 분석 결과, KiCad 쿠폰을 공개한 설계 흐름이 본 연구의 핵심 공학적 기여다.

코드와 자료 공개

SpinalHDL RTL, 실험 설정과 결과 CSV, Gemma 그래프 목록, 그림 원본, KiCad 원본, 논문과 발표자료는 다음 저장소에 공개한다.

KiCad 원본은 hardware/kicad/에 있으며 제작용 산출물이 아닌 참조 쿠폰이다.

Repository: <https://github.com/snowman0919/varp-k26-memory-fpga> **Release:** <https://github.com/snowman0919/varp-k26-memory-fpga/releases/tag/v11-conference-final>

모델 가중치는 라이선스와 용량 때문에 배포하지 않는다. 공개 압축 파일은 고정 해시의 그래프 목록과 제한된 타일 시험 입력만 포함한다.

참고문헌

- [1] W. Kwon et al., “Efficient Memory Management for Large Language Model Serving with PagedAttention,” arXiv:2309.06180, 2023.
- [2] T. Dao et al., “FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness,” arXiv:2205.14135, 2022.
- [3] E. Frantar et al., “GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers,” arXiv:2210.17323, 2022.
- [4] G. Xiao et al., “SmoothQuant: Accurate and Efficient Post-Training Quantization for LLMs,” arXiv:2211.10438, 2022.
- [5] J. Lin et al., “AWQ: Activation-aware Weight Quantization for LLM Compression and Acceleration,” arXiv:2306.00978, 2023.
- [6] B. Li et al., “FTRANS: Energy-Efficient Acceleration of Transformers using FPGA,” ISLPED, 2020.
- [7] S. Hong et al., “DFX: A Low-latency Multi-FPGA Appliance for Accelerating Transformer-based Text Generation,” MICRO-55, 2022.
- [8] S. Zeng et al., “FlightLLM: Efficient Large Language Model Inference with a Complete Mapping Flow on FPGAs,” arXiv:2401.03868, 2024.

- [9] S. Li et al., “DRAMsim3: A Cycle-Accurate, Thermal-Capable DRAM Simulator,” IEEE Computer Architecture Letters, vol. 19, no. 2, 2020.
- [10] AMD, Kria K26 SOM Data Sheet DS987.
- [11] AMD, Kria SOM Carrier Card Design Guide UG1091.
- [12] AMD, 7 Series FPGAs Packaging and Pinout UG475.
- [13] AMD, 7 Series FPGAs Memory Interface Solutions UG586.
- [14] KiCad Project, KiCad 9 Documentation, ERC and DRC reference.
- [15] R. D. Blumofe and C. E. Leiserson, “Scheduling Multithreaded Computations by Work Stealing,” Journal of the ACM, vol. 46, no. 5, pp. 720–748, 1999.
- [16] Q. Chen et al., “Locality-Aware Work Stealing Based on Online Profiling and Auto-Tuning for Multisocket Multicore Architectures,” HPDC, 2015.

부록 A. 재현 단위와 해석 원칙

본 개정에서 수치의 권위는 그림이 아니라 원본 CSV와 생성 코드에 있다. 직접 확인 자료는 ONNX 그래프의 노드·형상·가중치 구간, KiCad 객체 수처럼 원본에서 다시 셀 수 있는 값이다. RTL 시뮬레이션 자료는 Verilator가 handshake와 순차 논리를 진행해 만든 값이다. 분석 모델 자료는 명시된 작업·자원·비용 식이 만든 값이다. 보드에서 측정한 성능·전력·신호 품질 자료는 없다.

Gemma 작업 목록은 `projection_trace.csv`의 K/N 형상과 연산 순서를 입력으로 삼는다. 원본 가중치는 저장소에 넣지 않으며, 대표 타일만 허가된 로컬 모델에서 추출해 RTL 정확성 fixture로 사용한다. 합성 실험은 같은 부하와 시드의 S1/S2/S3가 같은 작업 목록 해시를 공유해야 유효하다. 재현 검증기는 완료 ID 집합, 중복 완료, timeout, 비용 필드와 manifest 해시를 함께 확인한다.

분석 결과는 보드 실측이나 기능적 언어 모델 추론으로 확대하지 않는다. 특히 p95와 p99는 의존성에서 해제된 TileJob의 완료 지연이다. 32토큰 조건은 동일한 의존성 그래프를 직렬 반복한 것이며, KV cache가 증가하는 실제 텍스트 생성은 아니다.

부록 B. 페루프 논리 RTL 구조

ClosedLoopVirtualPrototypeTop은 작업 수락, DMA 요청 FIFO, 다중 채널 스케줄러, DDR 응답 경계, 논리 링크 FIFO, job ID 결합, 대기열 정책, MatVec 결과를 하나의 역할 흐름으로 연결한다. 메모리 응답이 들어오기 전에는 연산 명령을 만들 수 없고, 같은 응답은 한 번만 수락된다. 기존 K26WorkStealingTop의 스케줄러·메모리·링크 평면은 독립적인 구조 실험으로 남겨 두고, 새 top을 페루프 논리 검증 경로로 쓴다.

대표 검증은 Gemma의 `gate_proj`, `lm_head`, `o_proj`에서 추출한 16×4 INT8 타일 세 개를 사용한다. 각 타일은 작업 수락 →DMA 요청→메모리 응답→MatVec 결과 순서를 지켰고 결과는 소프트웨어 INT32 내적과 일치했다. 수락/요청/응답/결과 사이클은 각각 5/11/13/88, 89/95/97/172, 173/179/181/256이다. 이 범위는 실제 가중치가 논리 데이터 경로를 통과했다는 사실만 확인한다.

GTH 직렬화, 레인 결합, CDC, 패킷 분할, CRC 재전송, 크레딧 반환은 구현되지 않았다. DDR 응답은 MIG 경계에서 주입하므로 DDR3L PHY와 보정도 검증하지 않았다. 따라서 논리 링크 폭과 FIFO 깊이는 구조 사실이지만 Fmax, 물리 대역폭, 보드 처리율은 아직 말할 수 없다.

부록 C. Gemma 투영에서 TileJob으로의 변환

Gemma 3 1B ONNX 그래프는 7,837개 노드와 183개 dense 투영을 토큰마다 가진다. Attention의 q/k/v/o가 104개, MLP의 gate/up/down이 78개, `lm_head`가 1개다. 원본 float32 투영 가중치는 약 4.0 GiB이고 명시적 INT8 변환 뒤 약 1.0 GiB로 모델링한다.

개정 모델은 투영 하나를 작업 하나로 두지 않는다. 각 투영의 전체 K차원을 유지하고 $N \leq 1024$ 인 출력 구간으로 나누어 토큰당 802개 TileJob을 만든다. q/k/v→o, o→gate/up, gate/up→down, down→다음 계층의 보수적 장벽을 둔다. 다음 토큰은 현재 토큰의 lm_head가 끝난 뒤에만 열린다. 따라서 32토큰은 25,664개 TileJob의 직렬 의존성 반복이다.

초기 배치는 네 가지다. 기존 산술 규칙은 C0/C1/C2/C3에 464/208/78/52개 타일을 둔다. 라운드로빈은 201/201/200/200개로 나눈다. 크기 균형은 누적 MAC이 작은 클러스터에 다음 작업을 뒤 198/202/200/202개가 된다. 채널 친화는 가중치 채널과 같은 번호의 클러스터를 우선해 394/136/136/136개가 된다. 이 네 배치는 실제 컴파일러 결과가 아니라 설계 민감도 변수다.

부록 D. 정책과 원격 복사 비용

S1은 자기 대기열만 선착순으로 처리하는 정적 다중 대기열이다. S2는 유향 클러스터가 다른 대기열의 가장 오래된 작업을 가져온다. S3는 예상 대기 감소에서 가중치·활성값·부분합 이동과 링크 불일치 비용을 뺀 점수가 양수일 때만 가져온다.

작업 이동은 단순 ownership counter가 아니다. 모델은 정적 배치의 선호 링크로 가중치를 먼저 공급한 뒤, 실행 클러스터가 바뀌면 가중치·활성값·부분합의 추가 바이트를 새 링크로 복사한다. 기본 링크 서비스와 추가 복사 서비스의 바이트·사이클을 별도 필드로 보존하고, 두 서비스 모두 완료시간 계산에 들어간다. 따라서 S3가 S2보다 작은 원격 작업을 골라 비지역 가중치를 줄일 수 있어도 S1보다 느릴 수 있다.

의존성 있는 작업은 모든 선행 작업이 끝나야 대기열에 들어간다. TileJob 지연의 시작점은 원래 생성 시각이 아니라 의존성 해제 시각이다. 이 정의는 단계 장벽 때문에 기다린 시간을 스케줄러 지연으로 잘못 세지 않는다.

부록 E. 합성 부하의 동일 시드 쌍비교

분석 모델 기본값은 클러스터 4개, 메모리 채널 4개, 논리 링크 묶음 4개, 묶음당 128비트다. 각 합성 부하는 1,000개 작업이며 시드 다섯 개를 사용한다. 정책별 중앙값을 먼저 비교하지 않고, 같은 시드의 S3/S1 또는 S3/S2 변화율을 계산한 뒤 그 변화율의 중앙값을 보고한다.

균형 부하에서 S3와 S1의 완료시간·p95·p99 차이는 모두 0%다. 채널 집중 부하도 p95와 p99 차이가 0%이며 완료시간만 -0.06%다. 순간 집중 부하는 p95 -0.08%, p99 -1.16%로 효과가 작다. 이 조건들은 연산 클러스터의 빈 시간이 이동 비용을 상쇄할 만큼 크지 않다.

혼합 부하에서는 S3가 S1보다 완료시간 15.91%, p95 17.70%, p99 16.92% 짧다. 편향 부하에서는 각각 17.25%, 19.13%, 18.71% 짧다. 같은 편향 부하의 S2와 비교하면 S3의 비지역 가중치가 35.49% 적고 완료시간 차이는 +0.01%로 거의 같다. 즉, 지역성 인식은 가장 오래된 작업을 무조건 가져오는 것보다 전송량을 줄이지만, 그 자체가 언제나 추가 완료시간 이득을 주는 것은 아니다.

다섯 시드는 제한된 민감도이며 통계적 모집단을 대표하지 않는다. 신뢰구간이나 유의확률을 제시하지 않고 중앙값과 조건별 방향만 해석한다. 이 합성 수치는 Gemma 실행 성능으로 옮겨 읽지 않는다.

부록 F. Gemma 형상의 초기 배치 민감도

기존 산술 배치에서 S3는 S1보다 완료시간이 4.80% 길고 TileJob p95도 0.28% 길다. 추가 링크 이동량은 토큰당 395.2 MB다. 라운드로빈에서는 완료시간이 0.59% 짧고 p95 변화는 없으며 추가 이동량은 43.3 MB다. 크기 균형에서는 완료시간이 0.76% 짧고 p95 변화는 없으며 추가 이동량은 110.8 MB다.

채널 친화 배치에는 큰 작업 쏠림이 남아 있다. 이 조건에서 S3는 완료시간을 7.56%, TileJob p95를 19.79% 줄이지만 추가 이동량은 토큰당 416.4 MB다. 결과는 “S3가 항상 빠르다”가 아니라 “초기 배치 뒤 남은 불균형이 이동 비용보다 클 때만 효과가 있다”를 지지한다. 실제 컴파일러 배치가 확보되면 네 민감도 중 어느 조건과 가까운지 다시 확인해야 한다.

부록 G. K26 로컬과 외부 메모리 후보

용량 모델은 INT8 가중치, 문맥 길이 32K의 KV cache, 활성값과 실행 여유분을 합해 2.43 GiB를 얻는다. 이는 명목 K26 4GB 안에 들어간다. 따라서 외부 8GB는 Gemma 1B 용량에 반드시 필요한 구성이 아니다.

크기 균형 S1에서 K26 로컬 유효 대역폭 4.8/9.6/14.4 GB/s의 완료시간은 45.0M/24.6M/17.8M 사이클이다. 외부 네 채널 합계 3.2/6.4/12.8 GB/s 후보는 238.3M/120.6M/62.4M 사이클이다. 외부 6.4 GB/s에서 링크 폭을 64비트에서 256비트로 넓혀도 결과가 거의 같아 메모리 공급이 병목임을 보인다.

이 값들은 실측치가 아니라 채택 임계값을 탐색하는 분석 입력이다. 시험한 범위에서는 외부 후보가 K26 로컬 기준선을 이기지 못했다. 외부 Memory FPGA의 다음 평가 조건은 3B 이상 모델, 더 긴 문맥, K26 로컬 경합, 독립 공급 경로가 필요한 다중 클러스터다. 전체 BOM과 보드 전력이 없으므로 저비용·저전력 달성을 주장하지 않는다.

부록 H. KiCad 라우팅 쿠폰의 실제 범위

KiCad 자료는 K26 모듈과 Memory FPGA가 실장된 전체 보드가 아니다. J1/J2의 일반 경계 커넥터, MLCC, 단일 DDR3L 메모리 slice와 일부 GTH·기준 클록 배선을 둔 축소 라우팅 쿠폰이다. 화면의 3D 렌더는 객체와 배선 위치를 설명할 뿐 제작 준비 상태를 보여 주지 않는다.

원본에는 footprint 29개가 있고 GTH·기준 클록 관련 단일 종단 net 20개가 명시적으로 라우팅되어 있다. 제한된 규칙에서 ERC/DRC 0이라는 결과는 쿠폰 subset에만 적용된다. 전체 설계의 핀 지정, 전원 트리, 네 DDR controller, K26 실제 커넥터, FPGA package, MIG 배치, 전체 라우팅과 제조 검증은 닫히지 않았다.

후속 단계는 정확한 MPN과 데이터시트, K26 커넥터 pinout, FPGA transceiver quad, MIG bank, stackup, 임피던스·손실·지터 예산, plane·stitching, PDN/SI/thermal/EMC, 제조 검사점을 요구한다. 그전에는 NOT FOR FABRICATION 표시를 유지한다.

부록 I. 빌드와 품질 관문

논문 빌드는 Markdown을 독립 HTML로 변환하고 SVG를 포함한 뒤 headless Chromium으로 PDF를 출력한다. 제출 원고는 A4 2단, 기술보고서는 A4 1단이다. 빌드 뒤 페이지 수, 텍스트 추출, 금지 주장, Figure 순서와 출처를 검사한다. SVG의 원본 글꼴과 최종 PDF 제목 글꼴의 비율로 최종 최소 글꼴을 보수적으로 계산하며 8pt 미만이면 실패한다.

재현 순서는 합성 실험, 의존성 인식 Gemma 실험, K26 로컬/외부 민감도, RTL 테스트, 논문 빌드다. 허가된 원본 Gemma 경로가 없더라도 저장된 trace와 대표 fixture로 핵심 검증을 반복할 수 있다. 모델 원본 가중치는 저장소와 release에 포함하지 않는다.

최종 해석은 세 문장으로 제한된다. 첫째, Gemma 1B에는 K26 로컬 구성이 우선이다. 둘째, 외부 메모리는 더 큰 모델·긴 문맥·로컬 경합이 확인될 때 다시 평가한다. 셋째, Work Stealing은 초기 배치가 남긴 불균형이 이동 비용보다 클 때만 켜다.